

PHÁT TRIỂN HỆ THỐNG PHÂN KHÚC VÀ GỢI Ý SẢN PHẨM THÔNG MINH

TÓM TẮT NỘI DUNG (ABSTRACT)

Báo cáo này trình bày quy trình nghiên cứu, thiết kế và triển khai một hệ thống hỗ trợ quyết định toàn diện dựa trên dữ liệu giao dịch thương mại điện tử quy mô lớn. Mục tiêu cốt lõi là tối ưu hóa giá trị vòng đời khách hàng (CLV) thông qua hai pha chính: (1) Phân khúc khách hàng bằng mô hình RFM kết hợp thuật toán **K-Means** và (2) Hệ thống gợi ý đa tầng (Hybrid) tích hợp **Collaborative Filtering** nội cụm và **Market Basket Analysis** (FP-Growth). Hệ thống được đóng gói qua **FastAPI** và quản lý theo quy trình **MLOps**, cho phép cập nhật mô hình từ phản hồi thực tế của người dùng. Kết quả thực nghiệm cho thấy hệ thống phân tách hiệu quả 3 nhóm khách hàng chiến lược từ tập dữ liệu ban đầu gồm **541,910** giao dịch.

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN

1.1. Lý do chọn đề tài và Bối cảnh nghiên cứu

Trong thập kỷ qua, sự bùng nổ của Thương mại điện tử (E-commerce) đã thay đổi hoàn toàn cục diện bán lẻ toàn cầu. Với hàng triệu giao dịch phát sinh mỗi ngày, doanh nghiệp không còn đối mặt với sự khan hiếm thông tin mà ngược lại, họ đang "ngộp" trong biển dữ liệu. Thách thức lớn nhất hiện nay không phải là thu thập dữ liệu, mà là chuyển hóa những con số vô hồn đó thành những hiểu biết có thể hành động (Actionable Insights).

Trong kinh doanh hiện đại, việc duy trì chiến lược "đối xử với mọi khách hàng như nhau" (One-size-fits-all) đã bộc lộ những sai lầm nghiêm trọng. Mỗi khách hàng đều có hành vi, sở thích và đóng góp tài chính khác nhau. Việc phân bổ nguồn lực Marketing một cách đại trà sẽ dẫn đến lãng phí ngân sách và bỏ lỡ cơ hội chăm sóc nhóm khách hàng trung thành (VIP).

1.2. Cơ sở khoa học của phương pháp RFM

Mô hình **RFM (Recency, Frequency, Monetary)** tập trung hoàn toàn vào hành vi thực tế của khách hàng:

- Recency (R):** Khoảng thời gian từ lần mua hàng cuối cùng đến hiện tại.
- Frequency (F):** Tổng số lần giao dịch, phản ánh lòng trung thành.
- Monetary (M):** Tổng số tiền đã chi trả, thước đo giá trị kinh tế.

1.3. Thách thức trong bài toán Gợi ý sản phẩm

Dự án tiếp cận bài toán gợi ý thông qua hai hướng: **Collaborative Filtering** (tương đồng người dùng) và **Association Rules** (luật kết hợp giữa các sản phẩm).

1.4. Mục tiêu nghiên cứu

1. Phân đoạn hành vi bằng kỹ thuật Clustering.
2. Cá nhân hóa gợi ý sản phẩm.
3. Vận hành thực tế trên nền tảng MLOps.

CHƯƠNG 2: DATASET VÀ QUY TRÌNH TIỀN XỬ LÝ DỮ LIỆU

2.1. Mô tả Dataset và Thống kê ban đầu

Nghiên cứu sử dụng tập dữ liệu giao dịch từ hệ thống bán lẻ trực tuyến (Online Retail). Đây là nguồn dữ liệu phản ánh hành vi mua sắm thực tế, bao gồm các thông tin chi tiết về từng hóa đơn.

- **Tổng số bản ghi thô:** 541,910 dòng.
- **Các thuộc tính chính:**
 - InvoiceNo: Mã hóa đơn (duy nhất cho mỗi lần thanh toán).
 - StockCode: Mã định danh hàng hóa.
 - Description: Mô tả tên sản phẩm.
 - Quantity: Số lượng mặt hàng.
 - InvoiceDate: Thời gian giao dịch.
 - UnitPrice: Giá trên một đơn vị sản phẩm.
 - CustomerID: Mã định danh khách hàng (duy nhất).
 - Country: Quốc gia của khách hàng.


2.2. Quy trình làm sạch và Biến động dữ liệu (Data Pipeline)

Dữ liệu thực tế thường chứa nhiều bản ghi không hợp lệ hoặc thiếu thông tin định danh. Quy trình Pipeline được thiết lập để làm sạch dữ liệu qua các bước sau:

Bước 1: Xử lý giá trị thiếu và Dữ liệu lỗi

Chúng tôi tiến hành loại bỏ các dòng có CustomerID trống và các đơn hàng có Quantity ≤ 0 (thường là các đơn giao dịch bị hủy hoặc hoàn trả).

- **Kết quả:** Dữ liệu giảm từ **541,910 dòng** xuống còn **406,830 dòng** hợp lệ.
- **Phân tích:** Việc giảm đi khoảng 25% dữ liệu chủ yếu do loại bỏ các giao dịch không có mã khách hàng (khách vắng lai). Trong bài toán phân khúc dựa trên lòng trung thành, việc xác định danh tính khách hàng là điều kiện tiên quyết; do đó, các giao dịch ẩn danh không mang lại giá trị cho việc xây dựng hồ sơ hành vi dài hạn.



Bước 2: Định danh khách hàng

Từ 406,830 giao dịch hợp lệ sau khi làm sạch, hệ thống thực hiện gom nhóm theo ID khách hàng. Kết quả xác định được **4,372 khách hàng duy nhất**. Đây là tập hợp các đối tượng sẽ được dùng để tính toán bộ chỉ số RFM.

2.3. Trích xuất đặc trưng RFM (Feature Engineering)

Từ tập hợp các giao dịch thô đã được làm sạch, chúng tôi tiến hành tổng hợp dữ liệu để tạo ra ba biến đặc trưng chính cho mỗi khách hàng:

- Recency (R):** Số ngày kể từ lần mua hàng cuối cùng của khách hàng đó đến thời điểm kết thúc kỳ dữ liệu. Công thức:

$$R = (Max_Date + 1) - Last_Transaction_Date$$

- Frequency (F):** Tổng số lượng hóa đơn (InvoiceNo) duy nhất mà khách hàng đã phát sinh. Điều này phản ánh cường độ quay lại của người dùng.

- Monetary (M):** Tổng giá trị giao dịch tích lũy của khách hàng, tính bằng

$$\sum (Quantity \times UnitPrice)$$

2.4. Xử lý Outlier và Chuẩn hóa dữ liệu

2.4.1. Xử lý giá trị dị biệt (Outlier) bằng phương pháp IQR

Trong dữ liệu thương mại điện tử, các giá trị dị biệt thường xuất hiện từ các nhóm khách hàng mua sỉ hoặc lỗi hệ thống. Chúng tôi sử dụng phương pháp **Interquartile Range (IQR)** để lọc bỏ các khách hàng có chỉ số R, F, M quá xa so với phân phối chung.

- **Kết quả:** Hệ thống loại bỏ **769 khách hàng** được xác định là Outliers.
- **Kết quả cuối cùng:** Tập dữ liệu sạch sẵn sàng cho mô hình gom cụm còn lại **3,603 khách hàng**.
- **Ý nghĩa:** Việc lọc bỏ Outliers đóng vai trò sống còn đối với thuật toán K-Means. Vì K-Means dựa trên khoảng cách Euclidean và trọng tâm (Centroid), các khách hàng có chi tiêu cực lớn (Siêu VIP) sẽ kéo lệch trọng tâm của các cụm, khiến các nhóm khách hàng đại đa số bị gom vào một cụm duy nhất, làm mất đi tính phân hóa của mô hình.

2.4.2. Chuẩn hóa dữ liệu (Feature Scaling)

Sử dụng **StandardScaler** để thực hiện Z-score normalization, đưa các biến R, F, M về cùng một thang đo với trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này đảm bảo tính khách quan khi tính toán khoảng cách giữa các chiều dữ liệu có đơn vị khác nhau.

2.5. Tổng kết quá trình tiền xử lý

Dưới đây là bảng thống kê sự biến đổi của quy mô dữ liệu qua các giai đoạn xử lý:

Giai đoạn	Đơn vị tính	Số lượng	Trạng thái
Raw Data	Dòng giao dịch	541,910	Dữ liệu gốc chưa xử lý
Cleaned Data	Dòng giao dịch	406,830	Loại bỏ ID trống & Quantity <= 0
Unique Customers	Khách hàng	4,372	Định danh duy nhất để tính RFM
Final Customers	Khách hàng	3,603	Loại bỏ 769 Outliers (IQR)

CHƯƠNG 3: THUẬT TOÁN VÀ MÔ HÌNH HÓA

Chương này tập trung mô tả chi tiết các cơ sở lý thuyết và quy trình triển khai các thuật toán học máy. Hệ thống được thiết kế theo cấu trúc hai giai đoạn: Giai đoạn 1 sử dụng các thuật toán gom cụm để định danh nhóm khách hàng; Giai đoạn 2 sử dụng các kỹ thuật gợi ý để cá nhân

hóa trải nghiệm mua sắm.

3.1. Thuật toán Gom cụm (Customer Segmentation)

Gom cụm là kỹ thuật học không giám sát nhằm chia tập dữ liệu khách hàng thành các nhóm sao cho các thực thể trong cùng một nhóm có độ tương đồng cao nhất và khác biệt nhất so với các nhóm còn lại.

3.1.1. Thuật toán K-Means Clustering

K-Means là thuật toán gom cụm dựa trên khoảng cách, hoạt động bằng cách tối thiểu hóa tổng bình phương khoảng cách giữa các điểm dữ liệu và tâm cụm (Centroid) tương ứng của chúng, hay còn gọi là Sum of Squared Errors (SSE):

$$SSE = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

Trong đó k là số cụm, C_i là cụm thứ i và μ_i là trọng tâm của cụm đó.

- **Lựa chọn số cụm ($k = 3$):** Để xác định giá trị k tối ưu, dự án sử dụng kết hợp hai phương pháp:
 - **Phương pháp Elbow (Cùi chỏ):** Quan sát điểm gãy tại đồ thị SSE, nơi mà việc tăng thêm số cụm không còn làm giảm đáng kể giá trị sai số.
 - **Silhouette Score:** Đo lường mức độ chống lẩn giữa các cụm. Giá trị $k = 3$ cho điểm Silhouette cao nhất, đảm bảo các cụm tách biệt rõ ràng và có mật độ tập trung tốt.

3.1.2. Thuật toán Hierarchical Clustering (Gom cụm phân cấp)

Để đối chứng và kiểm chứng tính ổn định của K-Means, chúng tôi triển khai thêm thuật toán **Agglomerative Hierarchical Clustering**. Phương pháp này tiếp cận theo hướng "từ dưới lên", bắt đầu bằng việc coi mỗi khách hàng là một cụm riêng biệt, sau đó liên tục gộp các cụm gần nhau nhất lại.

- **Ward's Linkage:** Kỹ thuật liên kết được chọn là Ward, nhằm tối thiểu hóa sự gia tăng của tổng phương sai trong cụm sau khi gộp. Việc sử dụng thuật toán này giúp chúng tôi quan sát được sơ đồ hình cây (Dendrogram), từ đó xác nhận cấu trúc phân tầng tự nhiên của dữ liệu khách hàng trước khi cố định số cụm trong K-Means.

3.2. Hệ thống Gợi ý Cá nhân hóa (Recommendation Engine)

Hệ thống gợi ý được xây dựng theo kiến trúc lai (Hybrid) để tận dụng lợi thế của cả hành vi tương đồng và mối liên hệ giữa các sản phẩm.

3.2.1. Lọc cộng tác dựa trên cụm (Cluster-based Collaborative Filtering)

Thay vì tính toán độ tương đồng trên toàn bộ 3,603 khách hàng (gây tốn kém tài nguyên), chúng tôi chỉ tính toán trong nội bộ từng phân khúc đã tìm được ở bước gom cụm.

- **Độ đo Cosine Similarity:** Được sử dụng để đo góc giữa hai vector khách hàng trong không gian sản phẩm. Khoảng cách này phản ánh sở thích mua sắm hơn là khối lượng mua sắm:

$$similarity(A, B) = \frac{A \cdot B}{||A|| ||B||}$$

- **Quy trình:** Hệ thống tìm ra 20 khách hàng lân cận có độ tương đồng cao nhất với khách hàng mục tiêu -> Trích xuất các sản phẩm mà nhóm lân cận này đã mua nhưng khách hàng mục tiêu chưa sở hữu -> Xếp hạng dựa trên tần suất xuất hiện để đưa ra gợi ý.

3.2.2. Khai thác luật kết hợp với FP-Growth

Để thực hiện chiến lược bán chéo (Cross-selling), thuật toán **FP-Growth (Frequent Pattern Growth)** được triển khai để tìm kiếm các Association Rules (Luật kết hợp).

- **Ưu điểm:** So với Apriori, FP-Growth hiệu quả hơn đáng kể về mặt tốc độ và bộ nhớ vì nó lưu trữ dữ liệu dưới dạng cấu trúc cây (FP-Tree) và chỉ cần quét tập dữ liệu 2 lần.
- **Các chỉ số đánh giá luật:**
 - **Support:** Tỷ lệ xuất hiện của bộ sản phẩm trong toàn bộ hóa đơn.
 - **Confidence:** Xác suất khách hàng mua mặt hàng B (Consequent) khi đã biết họ mua mặt hàng A (Antecedent).
 - **Lift:** Chỉ số quan trọng nhất, đo lường mức độ tăng trưởng xác suất mua B nhờ có sự xuất hiện của A. Nếu $Lift > 1$, mối quan hệ giữa A và B là thực sự có ý nghĩa và không phải ngẫu nhiên.

3.3. Quy trình thực thi và Tối ưu hóa mô hình

3.3.1. Xây dựng Ma trận Mua hàng (Purchase Matrix)

Dữ liệu giao dịch được chuyển đổi thành ma trận nhị phân (Binary User-Item Matrix), trong đó giá trị 1 đại diện cho việc khách hàng đã từng mua sản phẩm và 0 là chưa mua. Việc sử dụng ma trận nhị phân giúp tăng tốc độ tính toán Cosine Similarity và giảm nhiễu từ các đơn hàng có số lượng bất thường.

3.3.2. Cơ chế Checkpoint và Model Persistence

Để hệ thống vận hành ổn định trong môi trường thực tế (Production), chúng tôi áp dụng cơ chế lưu trữ mô hình:

- **Serialization:** Các mô hình đã huấn luyện (K-Means, StandardScaler) được lưu dưới dạng file .pkl bằng thư viện **Joblib**.
- **Matrix Checkpoint:** Các ma trận tương đồng và quy tắc kết hợp được lưu dưới dạng .npy

hoặc .json.

- **Lợi ích:** Tránh việc phải tính toán lại từ đầu (thường mất nhiều thời gian và tài nguyên CPU/RAM) mỗi khi hệ thống khởi động lại hoặc khi có yêu cầu gợi ý từ người dùng, từ đó giảm thiểu độ trễ (Latency).

3.4. Tổng kết sự kết hợp

Việc kết hợp **Gom cụm** và **Gợi ý** tạo nên một giải pháp toàn diện: Gom cụm giúp doanh nghiệp "vẽ chân dung" khách hàng để xây dựng chiến lược Marketing vĩ mô, trong khi Hệ thống gợi ý thực thi việc "tương tác cá nhân" để tối ưu hóa doanh thu vi mô trên từng đơn hàng.

CHƯƠNG 4: ĐÁNH GIÁ MÔ HÌNH VÀ KIỂM CHỨNG THỰC NGHIỆM

Sau khi xây dựng các mô hình học máy, bước đánh giá đóng vai trò quyết định để xác nhận tính chính xác và khả năng ứng dụng thực tế của hệ thống. Chương này trình bày các thước đo định lượng cho cả hai bài toán: Gom cụm khách hàng và Gợi ý sản phẩm, đồng thời xem xét hiệu suất hệ thống dưới góc độ MLOps.

4.1. Đánh giá kết quả Gom cụm (Clustering Evaluation)

Việc đánh giá các mô hình không giám sát (Unsupervised Learning) gặp nhiều thách thức do không có nhãn (label) thực tế để đối chiếu. Chúng tôi sử dụng các kỹ thuật thống kê để xác định độ tin cậy của các phân khúc khách hàng.

4.1.1. Phương pháp Elbow (Đường cong cùi chỏ)

Chúng tôi đánh giá sự thay đổi của tổng bình phương sai số nội cụm (SSE - Within-Cluster Sum of Squares) khi số lượng cụm k thay đổi từ 1 đến 10.

- **Phân tích đồ thị:** Tại giá trị $k = 3$, đồ thị SSE xuất hiện một "điểm gãy" (elbow point) rõ rệt. Tại đây, tỷ lệ giảm của SSE bắt đầu chậm lại đáng kể. Việc chọn $k = 3$ cho thấy chúng ta đã đạt được sự cân bằng tối ưu giữa việc giảm sai số và việc duy trì một số lượng cụm đủ nhỏ để có ý nghĩa trong quản trị kinh doanh.

4.1.2. Hệ số Silhouette (Dáng điệu)

Hệ số Silhouette (S) được sử dụng để đo lường mức độ tương đồng của một điểm dữ liệu với cụm của nó so với các cụm khác. Chỉ số này dao động từ -1 đến 1.

4. **Kết quả thực nghiệm:** Chỉ số Silhouette đạt giá trị dương cao tại $k = 3$ (xấp xỉ 0.4 - 0.5 tùy đợt mẫu).
5. **Ý nghĩa:** Một hệ số Silhouette dương và cao khẳng định rằng các cụm khách hàng được tách biệt tốt (khoảng cách liên cụm lớn) và có độ đặc đặc cao trong nội bộ cụm (khoảng cách nội cụm nhỏ). Điều này chứng minh hành vi khách hàng trong nhóm VIP, Tiềm năng và Nguy cơ có sự khác biệt rõ rệt về mặt bản chất.

4.1.3. So sánh đối chứng giữa K-Means và Hierarchical Clustering

Một phương pháp kiểm chứng quan trọng được thực hiện là so sánh kết quả của K-Means với thuật toán Gom cụm phân cấp (Hierarchical Clustering).

- **Nhận xét:** Mặc dù hai thuật toán có cơ chế hoạt động khác nhau (K-Means dựa trên centroid, Hierarchical dựa trên liên kết Ward), nhưng kết quả phân loại cuối cùng cho thấy sự tương đồng lên đến hơn 90% về mặt định danh khách hàng. Sự đồng nhất này khẳng định cấu trúc dữ liệu khách hàng chúng ta tìm thấy là thực tế và đáng tin cậy, không phải là kết quả ngẫu nhiên của một thuật toán cụ thể.

4.2. Đánh giá hệ thống Gợi ý (Recommendation Engine Evaluation)

4.2.1. Đánh giá Luật kết hợp (FP-Growth) qua chỉ số Lift

Trong khai thác luật kết hợp, các chỉ số Support và Confidence chỉ phản ánh tần suất. Chỉ số **Lift** mới là thước đo cho sức mạnh của luật:

- **Công thức:**
$$Lift(A \rightarrow B) = \frac{Support(A \cup B)}{Support(A) \times Support(B)}$$
- **Phân tích:** Các luật kết hợp được hệ thống lựa chọn đều có **Lift > 1** (thường từ 3.0 đến 15.0). Điều này chứng minh rằng việc khách hàng mua sản phẩm A thực sự thúc đẩy khả năng mua sản phẩm B một cách có ý nghĩa thống kê, chứ không phải do cả hai sản phẩm đều là những mặt hàng phổ biến.

4.2.2. Kiểm chứng Collaborative Filtering qua Cosine Similarity

Độ chính xác của gợi ý cá nhân hóa được kiểm chứng thông qua độ tương đồng Cosine giữa khách hàng mục tiêu và nhóm lân cận (neighbors).

- **Kết quả:** Hệ thống lọc ra các "hàng xóm" có độ tương đồng Cosine > 0.85 . Việc tìm ra những khách hàng có "vết mua sắm" gần như trùng khớp giúp đảm bảo rằng các sản phẩm gợi ý có tính liên quan cao đến sở thích tiềm năng của người dùng, giảm thiểu tỷ lệ gợi ý nhiễu.

4.3. Đánh giá tính sẵn sàng của hệ thống (MLOps Perspective)

Dưới góc độ vận hành thực tế, hệ thống được đánh giá qua khả năng phục vụ (Serving) và tính ổn định.

4. **Tốc độ phản hồi (Latency):** Nhờ việc sử dụng các mô hình đã được huấn luyện sẵn (Serialization qua Joblib) và tính toán tương đồng nội cụm, thời gian phản hồi trung bình

của API cho một yêu cầu gọi ý là **dưới 150ms**. Đây là ngưỡng tốc độ đảm bảo trải nghiệm người dùng mượt mà trên các ứng dụng thực tế.

- 5. **Khả năng mở rộng (Scalability):** Thay vì phải xử lý lại toàn bộ **541,910** dòng dữ liệu thô mỗi khi có yêu cầu, hệ thống chỉ cần nạp các tệp .pkl và thực hiện các phép toán ma trận nhanh chóng. Cơ chế Checkpoint này cho phép hệ thống dễ dàng mở rộng quy mô phục vụ hàng nghìn người dùng đồng thời mà không đòi hỏi tài nguyên tính toán quá lớn.
- 6. **Độ tin cậy của quy trình dự đoán:** Việc tách biệt giai đoạn chuẩn hóa (Scaling) và dự đoán đảm bảo dữ liệu mới đầu vào luôn được xử lý đúng theo phân phối đã huấn luyện, tránh hiện tượng lệch dữ liệu (Data Drift).

4.4. Tổng kết đánh giá

Thông qua các chỉ số Elbow, Silhouette và Lift, chúng tôi xác nhận mô hình đạt độ chính xác cao về mặt toán học. Đồng thời, các chỉ số về Latency và cơ chế lưu trữ mô hình khẳng định hệ thống đã sẵn sàng để triển khai trong môi trường thương mại điện tử thực tế.

(Nội dung tiếp theo: Chương 5 sẽ trình bày về Kiến trúc triển khai hệ thống với FastAPI và cơ chế thu thập Feedback...)

CHƯƠNG 5: KẾT QUẢ THỰC THI VÀ PHÂN TÍCH KINH DOANH

Chương này trình bày các kết quả đầu ra của hệ thống sau quá trình huấn luyện và đánh giá. Những con số thống kê từ mô hình không chỉ phản ánh hiện trạng của doanh nghiệp mà còn là cơ sở để đưa ra các quyết định điều hành chiến lược.

5.1. Chân dung các phân khúc khách hàng (Customer Profiles)

Dựa trên kết quả từ thuật toán K-Means với $k = 3$, chúng tôi đã định danh được 3 nhóm khách hàng chính với các đặc điểm hành vi riêng biệt. Bảng dưới đây tóm tắt các chỉ số trung bình (Mean) của từng cụm:

Đặc trưng	Nhóm 1 - Khách hàng VIP	Nhóm 0 - Khách hàng Tiềm năng	Nhóm 2 - Nguy cơ rời bỏ
Số lượng khách hàng	820	1,875	908
Recency (Ngày)	~37	~50	~228

Frequency (Lần)	~5.6	~2.0	~1.5
Monetary (\$)	~1,847	~558	~404

5.1.1. Nhóm 1: Khách hàng VIP (Cluster 1) - "Nguồn sống của doanh nghiệp"

Đây là nhóm khách hàng có giá trị cao nhất. Với Recency thấp (37 ngày), họ đang tương tác rất tích cực. Tần suất mua hàng gấp gần 3 lần nhóm tiềm năng và giá trị chi tiêu gấp 4.5 lần nhóm nguy cơ. Nhóm này tuy chiếm số lượng ít nhưng đóng góp phần lớn doanh thu tích lũy.

5.1.2. Nhóm 0: Khách hàng Tiềm năng (Cluster 0) - "Lực lượng chủ đạo"

Chiếm đa số với 1,875 khách hàng. Họ có hành vi mua sắm khá ổn định nhưng chưa thực sự bứt phá về mặt chi tiêu. Khoảng cách quay lại (50 ngày) là một tín hiệu tốt, cho thấy họ vẫn đang cân nhắc doanh nghiệp cho các nhu cầu mua sắm thường xuyên.

5.1.3. Nhóm 2: Khách hàng Nguy cơ rời bỏ (Cluster 2) - "Dấu hiệu cảnh báo"

Gồm 908 khách hàng đã lâu không quay lại (trung bình 228 ngày - tương đương hơn 7 tháng). Chỉ số chi tiêu và tần suất đều ở mức thấp nhất. Nếu không có biện pháp can thiệp, nhóm này khả năng cao sẽ rời bỏ hệ thống hoàn toàn.

5.2. Trực quan hóa kết quả phân cụm

Hệ thống đã sinh ra các biểu đồ trực quan để hỗ trợ bộ phận quản lý theo dõi:

- 3D Scatter Plot (RFM Space):** Biểu đồ không gian 3 chiều cho thấy sự phân tách rõ rệt giữa 3 nhóm. Nhóm VIP nằm tách biệt ở vùng có trục Monetary cao và Recency thấp, trong khi nhóm Tiềm năng và Nguy cơ tập trung thành các khối đặc đặc hơn ở vùng chi tiêu thấp.
- Pie Chart (Market Share):** Thể hiện tỷ trọng khách hàng. Nhóm Tiềm năng chiếm ưu thế tuyệt đối về quy mô, khẳng định dư địa tăng trưởng của doanh nghiệp nằm ở việc chuyển đổi nhóm này lên VIP.

5.3. Kết quả từ Hệ thống Gợi ý (Recommendation Results)

5.3.1. Gợi ý cá nhân hóa (Collaborative Filtering)

Hệ thống đã thực hiện gợi ý thành công cho các cá nhân trong nội bộ cụm. Ví dụ: Một khách hàng thuộc nhóm VIP thường xuyên mua đồ trang trí nội thất sẽ nhận được gợi ý về các mẫu đèn mới dựa trên danh sách mua sắm của 20 "hàng xóm" có độ tương đồng cao nhất trong cụm VIP. Điều này giúp tăng tỷ lệ nhấp chuột (CTR) do sản phẩm gợi ý sát với sở thích tầng lớp.

5.3.2. Kết quả từ Luật kết hợp (FP-Growth)

Các quy tắc kết hợp được tìm thấy cung cấp cái nhìn sâu sắc về giỏ hàng. Ví dụ thực tế:

- 6. **Luật 1:** {White Hanging Heart T-Light Holder} → {Red Hanging Heart T-Light Holder}.
- 7. **Chỉ số:** Confidence: 0.8, Lift: 12.0.
- 8. **Phân tích:** Khách hàng có xu hướng mua trọn bộ màu sắc cho cùng một mẫu thiết kế. Đây là cơ hội tuyệt vời để tạo các gói Combo sản phẩm.

5.4. Triển khai Hệ thống qua FastAPI

Mô hình đã được triển khai thành công dưới dạng Web Service sử dụng **FastAPI**, cho phép tích hợp trực tiếp vào ứng dụng di động hoặc website bán hàng của doanh nghiệp.

- **Endpoint /predict:** Nhận vào thông tin giao dịch gần nhất của khách hàng mới, trả về nhãn cụm (VIP/Tiềm năng/Nguy cơ) gần như tức thì.
- **Endpoint /recommend:** Trả về danh sách Top 5 sản phẩm gợi ý cho từng ID khách hàng dựa trên ma trận tương đồng đã lưu trữ.
- **Feedback Loop:** Hệ thống có khả năng ghi nhận phản hồi của người dùng vào SQLite. Dữ liệu này sẽ được dùng để thực hiện việc tái huấn luyện (Re-training) nhằm điều chỉnh trọng số của các cụm nếu hành vi thị trường thay đổi.

5.5. Đề xuất Chiến lược Kinh doanh (Actionable Insights)

Dựa trên các phân tích trên, chúng tôi đề xuất bộ chiến lược Marketing 360 độ:

Nhóm khách hàng	Chiến lược trọng tâm	Hành động cụ thể
Nhóm VIP	Giữ chân & Tri ân	Tặng thẻ đặc quyền Premium, ưu tiên giao hàng miễn phí, tặng quà sinh nhật cá nhân hóa.
Nhóm Tiềm năng	Kích cầu & Nâng cấp	Gửi mã giảm giá cho đơn hàng tiếp theo (Upsell), gợi ý sản phẩm kèm theo (Cross-sell) dựa trên luật kết hợp.
Nhóm Nguy cơ	Cứu vãn & Tái tương tác	Chiến dịch "We miss you" với mã giảm giá sâu, gửi khảo sát tìm hiểu lý do khách hàng không quay lại.

